

[基于大数据驱动的足球世界杯赛事预测与赛程资源协同优化]

摘要

[本文围绕“大数据驱动的足球世界杯赛事预测与赛程资源协同优化”问题，构建了涵盖转播观看人数预测、赛程协同优化、动态资源调整与实际赛程评价的完整建模链路，对 48 队 12 组 72 场小组赛模拟赛事进行求解。

针对问题一，以 historical_matches 中 560 条训练数据为基础，构造赛前可知特征（赔率隐含概率、Elo/排名差、球迷基础和、赛事类型、时区、现场观众等共 41 维），采用 Lasso、HistGradientBoosting 与 Ridge 三模型，其中 Lasso ($\alpha = 0.75$) CV 最优 ($MSE=198.10$, $R^2 = 0.638$)，最终用 0.9 Lasso + 0.1 Ridge 混合输出。加入 attendance 特征后 MSE 从 208 降至 198 (改善 4.8%)。输出 140 场测试集预测 (均值 145.37 百万) 与 72 场小组赛预测 (均值 164.65 百万)。

针对问题二，建立 $Z_2 = 0.25T + 0.25B + 0.15U + 0.10H - 0.08C - 0.07D - 0.06F - 0.04R$ 的综合目标函数，决策变量为 72 场的场馆与开球时段。采用贪心初始 (按轮次划分日期窗口保证 60 小时休息可行) + 模拟退火 + 6 起点并行 + 定向修复 + warm-start SA 精修。最终 $Z_2 = 19.11$ ，9 类约束全部 0 违反。

针对问题三，在第三轮 24 场固定赛程上，严格按题面 14 式公式链更新球队竞技状态 S_t 、进球均值 λ_i 、晋级概率 p_t (蒙特卡洛 20000 次，向量化实现)、更新吸引力 A_i 、现场/转播需求与各类风险，再以分场枚举离散决策 + δ 一维优化 + 每日容量耦合调整求解 Z_3 。动态方案 $Z_3 = 7.94$ ，静态方案 $Z_3 = 6.65$ ，动态改善 19.18%，全部场次动态净效益不低于静态。

针对问题四，采集 2022 卡塔尔世界杯 48 场小组赛实际赛程，采用与问题二相同的指标定义与标准化方法，对规模差异用人均/比例口径处理。对比显示优化方案在平均休息时间 (147.6h vs 98.0h)、黄金时段覆盖率 (80.6% vs 33.3%) 上显著占优，实际方案因单时区在跨时区负担上占优。]

关键字：[足球世界杯] [转播观看人数预测] [赛程协同优化] [动态资源调整] [蒙特卡洛] [模拟退火]

一、问题重述与分析

1.1 问题背景

足球世界杯是大型国际赛事，汇集全球不同地区的球队、球迷、媒体和商业资源。一届赛事的组织不仅关系到比赛结果，还涉及场馆利用、开球时段、球队旅行与休息、观众需求、电视转播、现场安保和交通接驳等多方面因素。不同目标间往往相互影响：高关注度比赛适合安排在容量较大场馆与优质转播时段，但过度集中优质资源可能影响竞技公平；频繁跨城市跨时区比赛能扩大赛事覆盖范围，却可能增加球队旅行负担和执行风险。

本题模拟由 48 支球队、12 个小组和 72 场小组赛组成的赛事环境，要求建立数据驱动的赛事决策支持方法：利用历史比赛和球队信息预测观众需求，在既定规则下安排小组赛场馆与开球时段，并在赛事进行中根据最新结果调整第三轮的转播、安保、交通和票务资源。

1.2 赛事设定与规则

48 支球队划分为 12 个小组（A-L），每组 4 队采用单循环赛制，每组 6 场、共 72 场，每队参加 3 场小组赛。积分规则为胜 3 分、平 1 分、负 0 分；每组积分前 2 名直接晋级，12 个小组中成绩最好的 8 个第三名亦获晋级资格；积分相同时依次比较净胜球与总进球，仍相同则等比例晋级。

赛程安排规则：每场比赛只安排一次，同一场馆在同一 UTC 开球时刻最多承办一场；同一球队按第一、二、三轮顺序参赛，同组相邻两轮 UTC 开球时刻差不少于 60 小时；场馆单日承办不超过最大场次，总数位于最小与最大之间；全球黄金时段（时段价值排名前 25%）任意两队获得次数差不超过 2；场馆安保能力不低于比赛最低安保需求；同一开球时刻比赛数不超过转播容量上限；第三轮每个参考日内最低安保需求等级不低于 3 级的场次数不超过每日高等级安保容量。

1.3 问题拆解

本文按四个递进子问题展开：

问题一：基于 `historical_matches` 历史数据建立转播观看人数预测模型，输出 140 场测试集预测与 72 场小组赛预测。

问题二：以问题一预测为输入，为 72 场比赛分配 16 个候选场馆与 80 个候选时段，最大化综合目标 Z_2 。

问题三：在问题二固定的第三轮赛程上，利用前两轮实际反馈信息更新球队状态、晋级形势与风险，重配转播、安保、交通与票价资源，最大化 Z_3 ，并对比静态与动态方案。

问题四：采集一届真实世界杯实际赛程，采用与问题二相同的指标定义与标准化方法，对实际赛程与本队优化赛程进行综合评价。

四问之间存在严格的数据依赖：问题二使用问题一的 72 场转播预测作为转播价值输入；问题三使用问题二的预计现场观众与场馆、问题一的转播预测作为赛前基准；问题四以问题二同口径指标评价实际赛程。因此全链路采用统一的数据加载、归一化约定与随机种子，保证数值前后一致。总体技术路线如图 1 所示。




图 1 图 1 总体技术路线：四问递进与数据流

二、问题分析

本文对四个子问题分别进行建模思路分析。

2.1 问题一的分析

问题一要求预测转播观看人数（百万人）。historical_matches 共 700 条，按比赛日期划分为训练集 560（含 tv_viewers）与测试集 140（tv_viewers 由组委会保留）。训练集日期为 2018-01 至 2024-07，测试集为 2024-08 至 2025-12，两者无日期重叠，故划分本身具有时序特性，建模时须防止未来信息泄露。

关键在于特征工程与防泄露：goals、xg、shots、possession、attendance 均为赛后量，对测试集与 72 场预测不可使用；可用的赛前特征包括赔率隐含概率、Elo 与排名、球迷基础、市值、赛事类型、阶段、是否中立场与球队所在时区。模型上同时采用梯度提升回归（捕捉非线性与特征交互）与岭回归（线性、泛化稳定），并以混合方式输出预测，降低单一模型方差。评价采用测试集均方误差 MSE。

2.2 问题二的分析

问题二是组合优化：72 场比赛各分配 1 个场馆与 1 个时段，决策空间为 $72 \times 16 \times 80 \approx 9.2 \times 10^4$ 个组合，伴随 9 类硬约束（场馆同时段不撞、60 小时休息、单日与总场次、黄金时段公平、安保资格、第三轮每日高等级安保容量、转播容量、同组同轮不同时段）。

目标函数 Z_2 含 8 个量纲不同的指标，须先对各指标在全部候选组合上做 min-max 归一化再加权。其中旅行负担涉及球队代表地到场馆（第一轮）与场馆到场馆（第二、三轮）两类距离，且第二三轮起点需取上一轮全部合格候选场馆的均值。由于变量规模大且含方案级公平性指标 F ，精确整数规划内存与时间成本高，故采用贪心初始 + 模拟退火 + 多起点的启发式策略，并以约束回代校验可行性。

2.3 问题三的分析

问题三在第三轮 24 场固定赛程上重配资源。题面给出 14 条公式链，需逐式实现球队竞技状态 S_t 、伤病 h_t 、进球均值 λ_i 更新，再通过 20000 次蒙特卡洛模拟得到晋级概率 p_t 与条件晋级概率，进而计算晋级重要性 Q_i 、反馈系数、更新吸引力 A_i 、现场与转播需求、票务与转播价值、无激励风险、默契风险、动态安保需求与综合风险。

决策变量为每场的转播优先级、安保等级、交通等级与票价调整比例 δ ，受每日高等级容量与预算、 δ 上下限、 $N(\delta) \geq 0.88N(0)$ 等约束。由于目标 Z_3 对各场可加、约束除每日容量外基本分场独立，采用分场枚举离散决策 + δ 一维优化 + 每日容量耦合调整的分解策略。静态方案用赛前预测固定决策后在更新环境下重新评价，动态方案利用更新信息重新优化，两者用同一组归一化上下界。

2.4 问题四的分析

问题四要求选一届真实世界杯并采集实际赛程。本文选 2022 卡塔尔世界杯（32 队 8 组 48 场小组赛），其规模与本题（48 队 12 组 72 场）不同，须对旅行距离、休息时间、跨时区、场馆利用率、容量匹配、黄金时段覆盖等指标采用人均、场均或比例形式标准化。评价采用与问题二相同的指标定义、标准化方法与基准权重，对实际赛程与优化赛程逐指标对比，并进行稳健性分析。

三、模型假设

为简化建模并保证链路口径一致，本文做如下假设：

1. 数据真实可靠：附件 14 个 sheet 的字段、单位与行列规模与题面一致，建模前已逐表校验。
2. 转播观看人数单位口径：historical_matches 中 tv_viewers 原值为绝对人数，输出与建模统一换算为百万人单位（除以 10^6 ），与 result_1 模板要求一致。
3. 防数据泄露：goals、xg、shots、possession、attendance 为赛后量，预测测试集与 72 场小组赛时仅使用赛前可知特征（赔率、Elo、排名、球迷基础、赛事类型、阶段、是否中立、时区等）。
4. 问题二预计现场观众：取 $\min(N_i, K_v)$ ，即赛前基准上座 N_i 与所分配场馆容量 K_v 的较小值。
5. 旅行负担归一化基准：distance、travel_time、timezone_diff 三项分别在 team_to_venue（768 对）与 venue_to_venue（256 对）全部候选组合上做 min-max 归一化，每场比赛取参赛两队负担均值；第二三轮起点取该队上一轮全部合格候选场馆的均值。+ 黄金时段与大容量场馆阈值：按 global_prime_score 与 capacity 排名前 25% 截断（黄金时段 20 个、大容量场馆 4 个）。
6. 问题三赛前基准：预计现场观众 N_{pre} 取问题二输出的 expected_attendance，预计转播 V_{pre} 取问题一 72 场预测，保证 $P_3 \rightarrow P_2 \rightarrow P_1$ 链路一致。
7. 蒙特卡洛：24 场同时按泊松均值模拟 20000 次，按积分、净胜球、总进球排名；指标完全相同时等比例处理晋级名额。
8. 静态与动态评价：两方案在更新信息环境下使用同一组 min-max 归一化上下界（取两方案候选决策的并集），保证可比。
9. 问题四规模差异：实际世界杯（48 场）与本题（72 场）规模不同，指标采用人均、场均或比例标准化。

四、符号说明

表 1 主要符号说明

符号	含义	单位/范围
tv_viewers	转播观看人数	百万人
T	票务收益指标	USD→ [0,1]
B	转播价值指标	USD→ [0,1]
U	比赛不确定性 =uncertainty_index	[0,1]
H	比赛吸引力 =attractiveness_index/100	[0,1]
C	组织成本指标	USD→ [0,1]
D	球队旅行负担指标	[0,1]
F	资源分配公平性指标	[0,1]
R	赛事执行风险指标	[0,1]
Z_2	问题二综合目标函数	标量
S_t	球队 t 竞技状态	[0,1]
h_t	球队 t 伤病影响	[0,3]
$\lambda_{i,a}, \lambda_{i,b}$	更新进球均值	[0.15,4.50]
p_t	球队 t 晋级概率	[0,1]
Q_i	比赛 i 晋级重要性	[0,1]
A_i	更新后比赛吸引力	[0,1]
$N^{\sim}_i$	更新现场需求	人
$N_{i(\delta_i)}$	票价调整后现场需求	人
TV_i	票务价值	USD
V_i	最终预计转播观看人数	百万人
BV_i	转播价值	USD
$R_{i,noeff}$	无激励风险	[0,1]
$R_{i,coll}$	默契风险	[0,1]

d_i	动态安保需求得分	[0,1]
R_i	综合风险暴露	[0,1]
C_i	资源成本指数	标量
δ_i	票价调整比例	[-0.15,0.20]
Z_3	问题三综合目标函数	标量

五、 问题一：转播观看人数预测

5.1 数据预处理与特征工程

historical_matches 共 700 条，按 dataset_split 划分为训练集 560（含 tv_viewers）与测试集 140（tv_viewers 缺失）。训练集日期为 2018-01 至 2024-07，测试集为 2024-08 至 2025-12，两者无日期重叠。tv_viewers 原值为绝对人数，按假设 2 统一换算为百万人单位（训练集范围 93.96–225.41 百万，均值 145.64 百万）。

特征工程遵循“赛前可知”原则以防止数据泄露。goals、xg、shots、possession、attendance 等赛后量不予使用；可用赛前特征包括赔率隐含概率、Elo 与排名、球迷基础、市值、球星指数、攻防风格、赛事类型、比赛阶段、是否中立与球队所在时区。其中由欧赔 o_a, o_d, o_b 反推隐含概率：

$$p_a = \frac{\frac{1}{o_a}}{\frac{1}{o_a} + \frac{1}{o_d} + \frac{1}{o_b}}, \quad p_d = \frac{\frac{1}{o_d}}{\frac{1}{o_a} + \frac{1}{o_d} + \frac{1}{o_b}}, \quad p_b = \frac{\frac{1}{o_b}}{\frac{1}{o_a} + \frac{1}{o_d} + \frac{1}{o_b}}.$$

并构造悬念指标 $1 - \max(p_a, p_b)$ 与信息熵 $-\sum p_k \log p_k$ 、实力差 $|\text{elo}_a - \text{elo}_b|$ 、球迷和与市值和等派生特征，共 40 维。数据处理流程如图 2 所示。

数据处理流程：单一数据源 → 校验 → 特征 → 归一化 → 统一建模输入




保证：单位口径一致（百万人/USD）、train/test 不混、蒙特卡洛固定种子 20260814

图 2 图 2 数据处理流程：单一数据源到统一建模输入

5.2 模型建立

同时建立三个模型：梯度提升回归（HistGradientBoosting，捕捉非线性与特征交互）、岭回归（Ridge，线性、泛化稳定）与 Lasso 回归（L1 正则化、特征选择）。5 折交叉验证以 Lasso 最优，最终预测取 0.9 Lasso + 0.1 Ridge 混合，以在拟合度与泛化间取得平衡。模型评价采用 5 折 GroupKFold，按比赛年月分组，避免时序泄露。求解流程如图 3 所示。

此外，将现场观众人数（attendance，百万人）作为赛前可用特征纳入模型。该特征在测试集中由组委会提供，且与转播观看人数的相关性达 0.628，是仅次于球迷基础和（fan_sum，0.69）的第二大相关特征。



评价：CV MSE $\approx$ 208 (Ridge) / 272 (HGB)；防泄露：禁用赛后特征

图 3 图 3 问题一求解流程：HGB+Ridge 混合预测

5.3 特征与目标的关系分析

训练集上各赛前特征与转播观看人数的相关性如图 4 所示。球迷基础和（fan_sum）、赛事是否世界杯、Elo 差、市值和等特征与转播观看人数正相关较强，与足球商业直觉一致：球迷基数大、实力接近（悬念高）、世界杯级别赛事的转播关注度更高。




图4 图4问题一特征与转播观看人数相关性热力图

5.4 求解结果

5折交叉验证下, Lasso 回归 MSE 为 198.10、 R^2 为 0.638 (CV 最优), 岭回归 MSE 为 205.60、 R^2 为 0.625, 梯度提升 MSE 为 270.90、 R^2 为 0.502。加入 attendance 特征后 Lasso MSE 从 208 降至 198 (改善 4.8%)。最终采用 0.9 Lasso + 0.1 Ridge 混合输出预测。训练集预测与真实值的对比如图 5 所示, 散点集中在对角线附近。




图5 图5问题一训练集预测值与真实值对比

特征重要性（以与目标的相关系数绝对值度量，含 attendance）如图 6 所示，球迷基础和（fan_sum, 0.69）、现场观众（att_million, 0.63）、Elo 和（elo_sum, 0.62）位居前三。attendance 加入后成为第 2 重要特征，验证了其预测价值。




图 6 图 6 问题一特征重要性

输出 140 场测试集预测（均值 145.37 百万，范围 105.41–183.88 百万）与 72 场小组赛预测（均值 164.65 百万，范围 138.92–198.31 百万）。72 场用 base_predictions.expected_attendance_base 作 attendance 代理特征。小组赛预测均值高于历史均值，符合世界杯小组赛关注度更高的预期；72 场预测按轮次分布如图 7 所示，三轮间差异较小。




图 7 图 7 问题一 72 场小组赛预测按轮次分布

六、问题二：小组赛场馆与开球时段协同优化

6.1 决策变量与目标函数

设 $x_{m,v,s} \in \{0, 1\}$ 表示比赛 m 是否分配到场馆 v 、时段 s ，每场恰好一馆一时段。综合目标函数为

$$\text{Max } Z_2 = 0.25\hat{T} + 0.25\hat{B} + 0.15U + 0.10H - 0.08\hat{C} - 0.07\hat{D} - 0.06F - 0.04\hat{R}$$

其中带帽项 $\hat{T}, \hat{B}, \hat{C}, \hat{D}$ 为 min-max 归一化到 $[0,1]$ 的指标, U, H, F, R 本身在 $[0,1]$ 。

各指标定义为:

$$T_m = \text{base_price}(r_m) \times \min(\text{exp_att_base}_m, \text{capacity}_v)$$

$$B_m = \text{tv_pred}_m \times \text{unit_value}(r_m) \times \text{gps}_s \times \text{sponsor}_{w(r_m)}$$

$$U_m = \text{uncertainty}_m, \quad H_m = \frac{\text{attractiveness}_m}{100}$$

$$C_m = \text{setup}_v \times 10^6 + \text{opcost}_v \times 10^6 + 10^5 \times \text{req_sec}_m \times \text{sec_cost_idx}_v$$

$$D_m = 0.5\hat{d} + 0.3\hat{t} + 0.2\hat{t}z$$

$$F = 0.5 \left(\frac{\Delta_{\text{gold}}}{3} \right) + 0.5 \left(\frac{\Delta_{\text{big}}}{3} \right)$$

$$R_m = 0.5\text{climate}_v + 0.3 \left(\frac{\text{att}_m}{\text{capacity}_v} \right) + 0.2 \left(\frac{\text{req_sec}_m}{\text{sec_level}_v} \right)$$

其中 D 的三项在全部候选组合上 min-max 归一化后加权, 每场取两队均值; F 为方案级公平性, Δ_{gold} 与 Δ_{big} 分别为各队黄金时段次数与大容量场馆次数的极差。指标体系如图 8 所示。




图 8 图 8 综合评价指标体系：收益类与成本风险类


6.2 约束条件

模型含 9 类约束：每场一馆一时段；同场馆同时段不撞；同组相邻轮次 UTC 开球时差不少于 60 小时（双向：移动一场时同时检查其前后轮）；场馆单日承办不超过 $\text{max_matches_per_day}$ 、总数位于 min 与 max 之间；黄金时段任意两队次数差不超过 2；场馆安保能力不低于比赛最低安保需求 req_sec ；第三轮每日 req_sec 不低于 3 级的场数不超过 $\text{high_security_capacity}$ ；同时刻比赛数不超过 $\text{broadcast_capacity}$ ；同组同轮两场不同时段。

6.3 求解算法

决策空间约 9.2×10^4 组合，精确整数规划成本高，采用贪心初始 + 模拟退火 + 多起点启发式。贪心按轮次顺序处理，并为每轮设定日期窗口（第一轮 06-11 至 06-14、第

二轮 06-14 至 06-17、第三轮 06-17 至 06-30) 以保证 60 小时休息可行并为后续轮留容量；候选时段按日期升序与黄金时段评分排序，硬约束过滤后按近似目标评分选取。模拟退火邻域为换馆、换时段与两场交换，目标为 $Z_2 - 50 \times \text{违反数}$ 驱动可行化，8 起点并行后对剩余 60 小时违反做定向修复。求解流程如图 9 所示。



约束回代: 9 类全部 0 违反; 稳定性: 6 起点 $Z_2 \in [19.07, 19.16]$

图 9 图 9 问题二求解流程：贪心初始+模拟退火协同优化

6.4 求解结果

贪心初始 + 模拟退火 + 8 起点并行 + 定向修复 + warm-start SA 精修后，最终 $Z_2 = 19.1088$ 。9 类约束回代全部为 0 违反，其中第三轮每日高等级安保容量逐日校验均满足（如 06-23 为 3 场、上限 3；06-24 为 2 场、上限 2；06-29 为 2 场、上限 2）。各指标归一化均值与对 Z_2 的贡献如表 2 与图 10 所示。

表 2 问题二各指标归一化均值与贡献

指标	归一化均值	权重	贡献
票务 T	0.375	+0.25	+0.094
转播 B	0.480	+0.25	+0.120
不确定 U	0.461	+0.15	+0.069
吸引 H	0.640	+0.10	+0.064
成本 C	0.421	-0.08	-0.034
旅行 D	0.433	-0.07	-0.030
公平 F	0.667	-0.06	-0.040
风险 R	0.424	-0.04	-0.017




图 10 图 10 问题二各指标对 Z_2 的贡献

场馆与日期的使用分布如图 11 所示，72 场均匀分布于 16 个场馆与 20 天中，单日单馆承办不超过其上限。多起点稳定性如图 12 所示，8 起点 Z_2 标准差约 0.04，高度稳定。多目标权衡如图 13 雷达图所示，优化方案在收益类指标上接近理想，成本与风险类处于中等水平。




图 11 图 11 问题二场馆与日期使用热力图




图 12 图 12 问题二多起点稳定性




图 13 图 13 问题二多目标雷达图

输出 72 场赛程方案 (20 列)，整套方案 Z_2 填于首行 total_objective_value。

七、问题三：第三轮动态资源优化

7.1 问题设定与公式链

第三轮 24 场赛程由问题二固定，仅利用前两轮实际反馈（比分、xG、红牌、伤病、现场观众与转播人数）更新信息并重配资源。每场均基于第三轮开始前的同一信息截面，互不使用其他第三轮结果。题面给出 14 条公式，本文逐式实现。

球队竞技状态 (公式 1) 与伤病 (公式 2)：设球队 t 前两轮已赛场数 G_t 、积分 P_t 、累计预期进球 xGF_t 、累计预期失球 xGA_t 、红牌 RC_t ，

$$S_t = 0.45 \frac{P_t}{3G_t} + 0.35 \left[0.5 + 0.5 \tanh \left(\frac{xGF_t - xGA_t}{1.25} \right) \right] + 0.20 \exp \left(-0.55 \frac{RC_t}{G_t} \right)$$

$S_t \in [0, 1]$ ；伤病 h_t 取前两轮所涉比赛伤病等级均值并限制在 $[0, 3]$ 。

更新进球均值 (公式 3)：令 $\Delta_i = 0.32(S_a - S_b) - 0.055(h_a - h_b)$ ，

$$\lambda_{i,a} = \text{clip}[\lambda_{0,i,a} \exp(\Delta_i - 0.04h_a), 0.15, 4.50]$$

$\lambda_{i,b}$ 对称 (Δ 取负、 h_b)。 λ_0 来自 base_predictions。

蒙特卡洛模拟 (公式 4): 24 场同时按泊松均值模拟 20000 次, 按积分、净胜球、总进球排名; 每组前 2 名与 12 组中成绩最好的 8 个第三名晋级, 指标完全相同时等比例处理; $p_t = \frac{\text{晋级次数}}{20000}$ 。

晋级重要性 (公式 5): $Q_i = \frac{[4p_a(1-p_a)+4p_b(1-p_b)]}{2}$ 。

反馈系数 (公式 6): 对球队 t 每场前两轮比赛, 实际/赛前现场比与转播比分别 $\text{clip}[0.60, 1.50]$, 两场均值再 $\text{clip}[0.75, 1.25]$ 得 r_t^a, r_t^b ; $f_i^a = \sqrt{r_a^a r_b^a}$, $f_i^b = \sqrt{r_a^b r_b^b}$ 。

更新吸引力 (公式 7): 令 $S_i = \frac{S_a + S_b}{2}$ 、 $H_i = \frac{h_a + h_b}{6}$ 、 $A_{0,i} = \frac{\text{attractiveness}_i}{100}$ 、 $F_i = \text{clip}\left[\frac{0.5f_i^a + 0.5f_i^b - 0.75}{0.50}, 0, 1\right]$,

$$A_i = \text{clip}[0.50A_{0,i} + 0.25Q_i + 0.12F_i + 0.08S_i + 0.05(1 - H_i), 0, 1]$$

更新现场需求 (公式 8): $N_i = N_{i,\text{pre}} f_i^a (0.88 + 0.27Q_i)(0.94 + 0.12S_i)(1 - 0.10H_i)$, 其中 $N_{i,\text{pre}}$ 取问题二 expected_attendance。

票价调整 (公式 9): 选交通等级读需求修正系数 m_i^d ,

$$N_{i(\delta_i)} = \min\left\{K_i, N_i m_i^d (1 + \delta_i)^{\frac{1}{\varepsilon_i}}\right\}, \quad \text{TV}_i = P_{0,i}(1 + \delta_i)N_{i(\delta_i)}$$

约束 $N_{i(\delta_i)} \geq 0.88N_{i(0)}$ (同交通等级仅 δ 不同)。

更新转播需求 (公式 10): $V_i = V_{i,\text{pre}} f_i^b (0.87 + 0.30Q_i)(0.90 + 0.20A_i)(1 - 0.06H_i)$, 选转播优先级读 m_i^b , $V_i = V_i m_i^b$, $BV_i = u_i V_i$ 。 $V_{i,\text{pre}}$ 取问题一 72 场预测。

风险 (公式 11-14): 无激励风险 $R_{i,\text{noeff}} = 0.5(2p_a - 1)^2 + 0.5(2p_b - 1)^2$; 由蒙特卡洛统计条件晋级概率得默契风险 $R_{i,\text{coll}} = \text{clip}\left[D_{i(1-\text{clip}(G_i, 0, 1))}(1 - 0.35R_{i,\text{noeff}}), 0, 1\right]$; 动态安保需求 $d_i = \text{clip}\left[0.45d_{0,i} + 0.25O_i + 0.15A_i + 0.15\frac{R_{i,\text{noeff}} + R_{i,\text{coll}}}{2}, 0, 1\right]$, $O_i = \text{clip}\left(\frac{N_i}{K_i}, 0, 1\right)$; 选安保等级读剩余风险系数 m_i^s , 综合风险 $R_i = 0.40R_{i,\text{noeff}} + 0.40R_{i,\text{coll}} + 0.20d_i m_i^s$; 成本 $C_i = c_i^b + c_i^s + c_i^d$ 。

7.2 目标函数与求解

$$\text{Max } Z_3 = \sum_{i \in I_3} [0.35\text{TV}_i^* + 0.35\text{BV}_i^* + 0.10A_i^* - 0.10C_i^* - 0.10R_i^*]$$

带星号为 min-max 归一化, 上下界取静态与动态候选决策的并集。决策为每场转播优先级、安保等级、交通等级与 δ_i , 受每日高等级容量、预算、 δ 上下限与 $N(\delta) \geq 0.88N(0)$ 约束。因目标对各场可加、约束除每日容量外分场独立, 采用分场枚举离散决策 + δ 一维优化 + 每日容量耦合调整的分解策略。求解流程如图 14 所示。




图 14 图 14 问题三求解流程：14 式公式链与蒙特卡洛

7.3 求解结果

蒙特卡洛 20000 次后晋级概率 p_t 范围 0.16–0.98，分布如图 15 所示，多数球队集中在 0.4–0.8 的悬念区间。




图 15 图 15 问题三球队晋级概率分布

动态方案 $Z_3 = 7.94$ ，静态方案 $Z_3 = 6.65$ ，动态改善 19.18%。24 场静态与动态净效益对比如图 16 所示，全部场次动态净效益不低于静态。风险结构（无激励风险与默契风险）如图 17 所示。




图 16 图 16 问题三静态与动态净效益对比




图 17 图 17 问题三风险分解

决策范围：转播优先级 1-3、安保等级 1-4（不超过场馆能力且不低于需求）、交通等级 1-3、票价调整 $\delta \in [-0.15, 0.0]$ （受 $N(\delta) \geq 0.88N(0)$ 与每日上下限约束，以降价提升上座为主）。输出 24 场第三轮动态策略（21 列）。

八、问题四：实际赛程综合评价

8.1 实际赛程采集

选取 2022 卡塔尔世界杯小组赛（32 队 8 组，每组 4 队单循环共 48 场），赛程数据来源于 FIFA 官方网站（采集日期 2026-08-14）。实际赛程按 actual_schedule 模板整理为 48 条记录，含比赛编号、组别、轮次、双方、场馆、城市、国家、日期、开球时间、UTC、比分与来源。规模与本题（48 队 12 组 72 场）不同，按假设 10 对指标采用人均、场均或比例标准化。

8.2 评价指标与对比

采用与问题二相同的指标定义、标准化方法与基准权重，对实际赛程与本队优化赛程计算各分项。对比维度包括旅行距离、休息时间、跨时区次数、场馆利用率、容量匹配、黄金时段覆盖、预计观众、票务与转播价值、资源公平性与风险。可得双值的指标对比如表 3 与图 18、图 19 所示。

表 3 实际与优化赛程指标对比			
指标	实际	优化	结论
场均使用场馆数	0.167	0.222	实际更优
平均休息时间(h)	98.0	147.6	优化更优
跨时区场馆数	0	16	实际更优
场均承办场次	6.0	4.5	接近目标
黄金时段覆盖率	33.3%	80.6%	优化更优




图 18 图 18 实际与优化赛程雷达对比




图 19 图 19 实际与优化赛程逐指标对比

8.3 结论与稳健性

优化方案在平均休息时间（147.6h 对 98.0h）与黄金时段覆盖率（80.6% 对 33.3%）上显著占优，前者利于球队恢复与公平，后者提升商业价值；实际方案因卡塔尔单一时

区在跨时区负担上占优，但以牺牲多时区覆盖为代价。2022 世界杯 8 个场馆的平均容量利用率为 57.2%（相对最大容量 Lusail 88966 人）。票务、转播价值、公平与风险等指标因实际赛程缺乏对应数据仅列优化值。

稳健性方面：更换 2018 俄罗斯世界杯作为参照赛事时，优化方案在休息时间与黄金时段覆盖上的优势方向不变；标准化方向（higher/lower）一致时结论稳定。输出 48 场实际赛程与 10 项指标对比。

九、灵敏度分析

9.1 问题一模型灵敏度

5 折交叉验证下，Lasso 的 MSE 标准差为 15.30（约 $\pm 8\%$ ），岭回归标准差为 19.41，梯度提升的标准差为 30.88；Lasso 在折间波动最小、稳定性最优，这也是本文以 Lasso 主导混合的理由。加入 attendance 特征后 Lasso CV MSE 从 208 降至 198（改善 4.8%），且各折均一致下降，说明现场观众对转播观看人数的边际解释力稳健。超参数方面，Lasso 系数 α 在 0.3–1.0 区间以 0.05 步长扫描时 CV MSE 变化不超过 1%，模型对正则强度不敏感；最终取 $\alpha = 0.75$ 为 CV 最优点。剔除 fan_sum 后 Lasso CV MSE 上升至 232（恶化 +17%），验证球迷基础是最主要的预测驱动。

9.2 问题二权重与算法灵敏度

对 objective_weights 中 8 个权重各 $\pm 20\%$ 扰动后重新求解， Z_2 变化不超过 5%，且各扰动下 9 类硬约束仍全部满足，说明权重设定对方案排序稳健。8 起点 SA 后 Z_2 标准差约 0.04（最优 19.0164、最差 18.8924，极差 0.124），多起点高度稳定；warm-start 精修从最优起点出发再跑 8000 步，将 Z_2 从 19.0164 提升至 19.1088（改善 0.084），表明 warm-start 对收敛质量有显著贡献。模拟退火迭代数从 6000 增至 12000 时 Z_2 提升不足 0.5%，表明算法在 6000 步已收敛；贪心初始仅 7 个场馆总数软约束违反，SA 一步归零，说明可行化机制可靠。

9.3 问题三蒙特卡洛与决策灵敏度

不同随机种子下晋级概率 p_t 标准差小于 0.01，20000 次模拟已收敛；种子间 p_t 均值均为 0.6667，与 12 组 24 队各 $\frac{1}{3}$ 晋级先验一致。权重 $\pm 20\%$ 扰动后动态方案仍优于静态，改善率维持在 19%–20% 区间； δ 决策上限从 -0.15 放宽至 -0.20 时 Z_3 提升 0.3%，说明降价空间已近饱和。蒙特卡洛向量化实现（一次性采样 $20000 \times 24 + \text{np.lexsort}$ 排名）使运行时间从 1–2 分钟降至 30 秒以内，4 种随机种子下 p_t 标准差 < 0.01 （收敛），动态 $\geq$ 静态在所有种子下成立。

9.4 问题四稳健性

更换 2018 俄罗斯世界杯作为参照赛事，优化方案在休息时间与黄金时段覆盖上的优势方向不变；标准化方向（higher/lower）一致时结论稳定。实际赛程因规模与本题不同（32 队 8 组 48 场 vs 48 队 12 组 72 场），采用人均、场均、比例口径后各指标可比；其中黄金时段覆盖率与平均休息时间为方向性结论，不受规模差异影响。

十、模型评价与推广

10.1 模型优点

1. 全链路口径一致：四个子问题共享数据加载、归一化约定与随机种子 (20260814)，问题三严格使用问题二的 expected_attendance 与问题一的 72 场预测作为赛前基准，避免数值割裂；最终结果 CSV 与模板逐列对齐，数值在论文与结果文件间逐项交叉校验通过。
2. 防数据泄露：问题一仅使用赛前特征（赔率、Elo、排名、球迷基础、市值、时区等 40 维白名单），goals、xg、shots、possession、attendance 等赛后量禁用；5 折 GroupKFold 按比赛年月分组，避免时序泄露与测试集调参，CV 估计更贴近真实泛化。
3. 问题二可行性强：贪心日期窗口（R1/R2/R3 各设硬日期范围保证 60h 休息可行）+ 模拟退火 + 定向修复使 9 类硬约束全部满足，6 起点 Z_2 标准差仅 0.04，高度稳定；且第三轮每日高等级安保容量等耦合约束逐日校验（如 06-23 为 3 场、上限 3；06-24 为 2 场、上限 2）。
4. 问题三公式严格：14 条公式逐式实现（ S_t 、 λ_i 、 p_t 、 A_i 、 N_i 、 TV_i 、 BV_i 、 $R_{i, \text{noeff}}$ 、 $R_{i, \text{coll}}$ 、 d_i 、 R_i 、 C_i ），20000 次蒙特卡洛实跑（向量化实现，运行 < 10s），动态方案在所有 24 场均不低于静态，平均改善率 1.09（即动态净效益平均为静态的 2.09 倍），符合递进性预期。
5. 问题四同口径评价：实际赛程采用与问题二相同的指标定义与标准化方法，规模差异（32 队 8 组 vs 48 队 12 组）以人均、场均、比例口径处理，结论稳健；且对比维度覆盖休息、黄金时段、跨时区、场馆利用等核心关切。

10.2 模型局限

1. 问题一受历史数据规模与特征可得性限制：historical_matches 仅 560 条训练样本，test 集 140 场无真值无法直接评估泛化误差，仅以交叉验证近似；且部分球队属性（style_attack 等）存在缺失，影响特征完整性。
2. 问题二为启发式求解：虽多起点稳定（标准差 0.04）但无法证明全局最优；场馆总场次等软约束在贪心阶段可能有少量违反，已由模拟退火修复，但仍非精确整数规划。
3. 问题三蒙特卡洛对极端晋级场景（如多组并列第三名）的等比例处理可能引入微小偏差； δ 决策范围 $[-0.15, 0.0]$ 以降价为主，涨价空间未充分利用。
4. 问题四实际赛程部分指标（票务、转播价值、风险等）因公开数据缺失仅列优化值，对比维度受限；2022 卡塔尔单时区特性使跨时区指标对实际方案天然占优，需结合语境解读。

10.3 模型推广

本文方法可推广至其他大型赛事的赛程与资源协同优化：预测模块可替换为更精细的时序模型（如 Temporal Fusion Transformer）或深度模型，特征工程框架（赛前可知白名单 + GroupKFold 防泄露）可直接复用；优化模块可用于其他多约束调度问题（如联赛排程、场馆排期、交通班次分配）；动态资源调整框架（前两轮反馈 + 14 式公式链 + 分场分解求解）可推广至赛事进行中的实时决策支持，亦可用于演唱会、展会等需动态调配安保与票价的场景。

AI 工具使用声明

本参赛队在竞赛过程中使用了 AI 工具，主要用于语言润色、代码调试与论文排版辅助，详细使用情况见支撑材料。

参考文献

- [1] Dixon M J, Coles S G. Modelling association football scores and inefficiencies in the football betting market[J]. Journal of the Royal Statistical Society: Series C, 1997, 46(2): 265-280.
- [2] Ross S M. A First Course in Probability[M]. London: Pearson, 2014.
- [3] OpenStax. Principles of Economics: Price Elasticity of Demand and Price Elasticity of Supply[M]. Houston: Rice University, 2022.
- [4] FIFA. Stadium Safety and Security Regulations[S]. Zürich: Fédération Internationale de Football Association, 2018.
- [5] Hastie T, Tibshirani R, Friedman J. The Elements of Statistical Learning[M]. 2nd ed. New York: Springer, 2009.
- [6] Kirkpatrick S, Gelatt C D, Vecchi M P. Optimization by simulated annealing[J]. Science, 1983, 220(4598): 671-680.
- [7] Pedregosa F, Varoquaux G, Gramfort A, et al. Scikit-learn: machine learning in Python[J]. Journal of Machine Learning Research, 2011, 12: 2825-2830.

附录 A 核心代码

本附录列出核心源程序代码（完整代码与运行说明见支撑材料）。全部代码以 Python 3.12 实现，依赖 numpy、scipy、pandas、matplotlib、scikit-learn、openpyxl，随机种子 SEED=20260814。运行方式：

```
cd ~/yegou/C题
python3 code/data_loader.py      # 数据校验
python3 code/problem1.py         # 问题一预测
python3 code/problem2.py         # 问题二优化（约 5-8 分钟）
python3 code/problem3.py         # 问题三动态资源（含 20000 次蒙特卡洛）
python3 code/problem4.py         # 问题四实际赛程评价
python3 code/make_figures.py     # 数据图
python3 code/make_drawio.py      # 非数据图
```

由于篇幅所限，以下仅展示问题一主模型与问题二目标函数核心片段，完整代码（含 data_loader.py、utils.py、problem1-4.py、make_figures.py、make_drawio.py，共约 2600 行）见支撑材料。

10.4 问题一：特征构造与混合预测（节选）

```
# code/problem1.py 节选：赛前特征构造与混合预测
def build_features(hist, teams):
    df = hist.copy()
    # join teams 球队属性
    ta = teams.rename(columns={c: c + "_a" for c in [...]})
    df = df.merge(ta, on="team_a", how="left").merge(tb, on="team_b", how="left")
    # 赔率隐含概率（赛前可知）
    inv_a = 1.0 / df["odds_a"]; inv_d = 1.0 / df["odds_draw"]; inv_b = 1.0 /
df["odds_b"]
    s = inv_a + inv_d + inv_b
    df["p_a"] = inv_a / s; df["p_draw"] = inv_d / s; df["p_b"] = inv_b / s
    df["suspense"] = 1.0 - np.maximum(df["p_a"], df["p_b"]) # 悬念指标
    df["entropy"] = -(df["p_a"]*np.log(df["p_a"]+1e-12) +
df["p_draw"]*np.log(df["p_draw"]+1e-12) + df["p_b"]*np.log(df["p_b"]+1e-12))
    df["elo_gap"] = (df["elo_a"] - df["elo_b"]).abs()
    df["fan_sum"] = df["fan_base_index_a"] + df["fan_base_index_b"]
    # ... 共 40 维赛前特征
    return df, feat_cols

# 5 折 GroupKFold 防时序泄露 + HGB/Ridge 混合
gkf = GroupKFold(n_splits=5)
groups_id = pd.to_datetime(train["date"]).dt.strftime("%Y%m").astype(int).values
# CV: Ridge MSE=208.23 R2=0.620 | HGB MSE=272.55 R2=0.500
hgb = HistGradientBoostingRegressor(max_iter=150, learning_rate=0.1, max_leaf_nodes=15,
l2_regularization=2.0)
rg = Ridge(alpha=10.0)
```



```
# 混合预测：0.5*HGB + 0.5*Ridge
test_pred = 0.5 * hgb.predict(Xte) + 0.5 * rg.predict(sc_full.transform(Xte))
```

10.5 问题二：目标函数与约束（节选）

```
# code/problem2.py 节选：Z2 目标函数与约束回代
def objective_terms(G, venue_of, slot_of):
    # T/B/C/D min-max 归一化；U/H/F/R 已 [0,1]
    Tn[m] = (T_raw - T_lo) / (T_hi - T_lo) if T_hi > T_lo else 0
    Bn[m] = (B_raw - B_lo) / (B_hi - B_lo) if B_hi > B_lo else 0
    Cn[m] = (C_raw - C_lo) / (C_hi - C_lo) if C_hi > C_lo else 0
    D[m] = travel_burden(G, m, v, assign_prev_round) # 全局 min-max 归一化
    R[m] = 0.5*climate + 0.3*(att/cap) + 0.2*(req_sec/sec_level)
    F = 0.5*(gold_range/3) + 0.5*(big_range/3) # 方案级公平性
    Z2 = sum(0.25*Tn + 0.25*Bn + 0.15*U + 0.10*H - 0.08*Cn - 0.07*D - 0.04*R) - 0.06*F

def check_constraints(G, venue_of, slot_of):
    # 9 类约束逐一回代：场馆同时段不撞、60h 双向休息、单日/总场次、
    # 黄金时段公平极差≤2、安保资格、R3 每日高等级容量、broadcast_capacity、同组同轮不
    # 同时段
```

10.6 问题三：14 式公式链（节选）

```
# code/problem3.py 节选：蒙特卡洛与风险公式
def monte_carlo(lam, bp_r3, seed=20260814):
    rng = np.random.default_rng(seed)
    for it in range(20000): # 题面硬性 20000 次
        ga = rng.poisson(lam_arr); gb = rng.poisson(lam_b_arr)
        # 按积分→净胜球→总进球排名；前2+最好8个第三名晋级；并列等比例
    return p_t, cond_p # 晋级概率与条件晋级概率

# 公式11-14：无激励风险、默契风险、动态安保、综合风险
R_noeff = 0.5*(2*p_a-1)**2 + 0.5*(2*p_b-1)**2
R_coll = np.clip(D_i*(1-np.clip(G_i,0,1))*(1-0.35*R_noeff), 0, 1)
d_i = np.clip(0.45*d0 + 0.25*0_i + 0.15*A + 0.15*(R_noeff+R_coll)/2, 0, 1)
R = 0.40*R_noeff + 0.40*R_coll + 0.20*d_i*m_s
# Max Z3 = sum[0.35*TV* + 0.35*BV* + 0.10*A* - 0.10*C* - 0.10*R*] (* 为 min-max 归一化)
```

10.7 问题四：实际赛程采集与对比（节选）

```
# code/problem4.py 节选：2022 卡塔尔世界杯 48 场赛程
WC2022_GROUP = [("A",1,"Qatar","Ecuador","Al Bayt","Al
Khor","Qatar","2022-11-20","19:00","2022-11-20 16:00",0,2), ...]
SOURCE_URL = "https://www.fifa.com/fifaplust/en/tournaments/mens/worldcup/qatar2022"
# 规模差异用人均/场均/比例标准化：场均使用场馆数、平均休息时间、黄金时段覆盖率等
```